3D Gaussian Splatting

Od fotografií k interaktívnej 3D scéne

PVSO – Cvičenie

Počítačové videnie a spracovanie obrazu

2026

Čo dnes urobíme

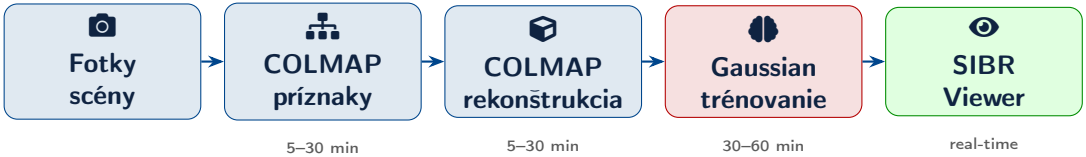

Teória (táto prezentácia)

- Ako COLMAP „vidí"3D zo 2D
- Čo sú 3D Gaussiány
- Ako prebieha trénovanie

Cvičenie

- Nasnímať scénu kamerou Ximea
- Spustiť COLMAP GUI v Dockeri
- Natrénovať vlastný model

Problém: ako dostať 3D z 2D fotografií?

Fotografia je **strata informácie** – 3D scéna sa premietne do 2D:

$$\mathbf{p}_{2D} = \mathbf{K} \cdot [\mathbf{R} \mid \mathbf{t}] \cdot \mathbf{P}_{3D}$$

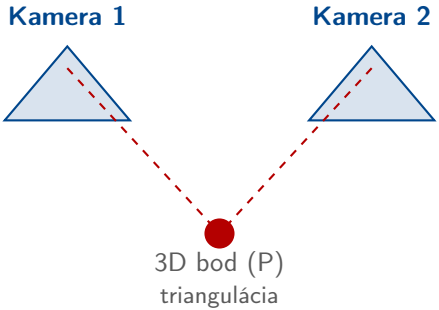

Čo vieme z jednej fotky?

- farbu pixelov ✓
- smer lúča kamery ✓
- **hĺbku (vzdialenosť)?** ×

Riešenie: viac fotografií z rôznych uhlov
⇒ **triangulácia**

Väzba na predchádzajúce prednášky

Kamera model $\mathbf{K}$, $[\mathbf{R}|\mathbf{t}]$ – PVSO prednáška 1. Príznaky, Harris detektor, RANSAC – prednáška 7.

COLMAP – Krok 1: Príznaky a Matching

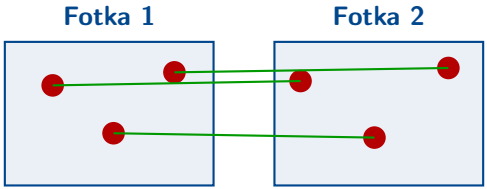

korešpondencie (SIFT matching)

$\Downarrow$ triangulácia $\Rightarrow$ sparse 3D body

Feature Extraction (SIFT)

Nájdenie **kľúčových bodov** – podobné Harrisovmu detektoru rohov (prednáška 7). Pre každý bod: *deskriptor* (128-dim vektor).

Feature Matching

Nájdenie **korešpondenčných párov** medzi fotkami – porovnanie deskriptorov, filtrácia pomocou **RANSAC** (prednáška 7).

COLMAP – Krok 2: Sparse Rekonštrukcia a Undistortion

Sparse Reconstruction (SfM)

Z korešpondencií COLMAP vypočíta:

- **pozície kamier** $[\mathbf{R}|\mathbf{t}]$ v 3D priestore
- **sparse mrak bodov** – tisíce 3D bodov

Výsledok: `cameras.bin`, `images.bin`, `points3D.bin`

Undistortion (`convert.py`)

Reálne objektívy **skresľujú** obraz (radiálna distorzia). 3DGS potrebuje **ideálny pinhole model**:

- COLMAP vypočíta parametre distorzie
- `convert.py` vytvorí undistortované

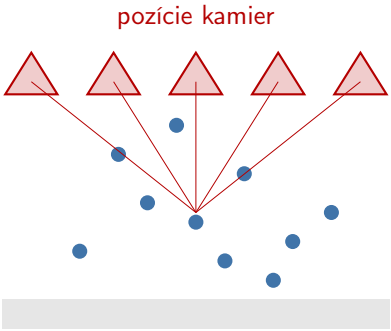

3D Gaussian Splatting – základná myšlienka

Kerbl et al., SIGGRAPH 2023 – scéna ako **milióny 3D Gaussiánov**, každý popisuje jeden „kúsok"scény.

Prečo Gaussiány?

- **explicitná** reprezentácia (na rozdiel od NeRF)
- rýchle renderovanie – **real-time**
- ľahko diferencovateľné ⇒ optimalizácia
- plynulé prechody a transparentnosť

Porovnanie s NeRF

	NeRF	**3DGS**
Reprezentácia	implicitná (MLP)	explicitná
Renderovanie	minúty	**real-time**

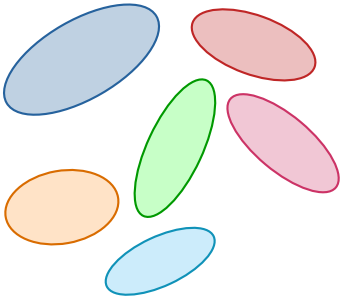

milióny Gaussiánov = scéna

3D Gaussián – čo ho popisuje

Každý Gaussián má **tieto parametre** (optimalizujú sa pri trénovaní):

Poloha	Tvar	Priehľadnosť	Farba
$\boldsymbol{\mu} \in \mathbb{R}^3$	$\boldsymbol{\Sigma} \in \mathbb{R}^{3\times 3}$	$\alpha \in [0, 1]$	Spherical Harmonics (SH)
stred Gaussiánu v 3D priestore	kovariančná matica (veľkosť, orientácia)	opacity – ako veľmi je Gaussián „viditeľný"	farba závisí od smeru pohľadu

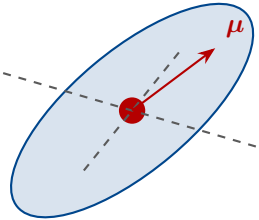

$\alpha = 0.8$

farba $= f(\text{smer})$

$\boldsymbol{\Sigma} =$ elipsoid

Splatting – ako sa 3D Gaussiány premietajú na 2D

Renderovanie = premietnutie 3D Gaussiánov do 2D obrazu

1. **Projekcia**: každý 3D Gaussián → 2D elipsa
   (kamerová projekcia – prednáška 1)
2. **Zoradenie**: podľa hĺbky od najbližšieho
3. **Alpha blending**: farby cez seba (α):

$$C = \sum_i c_i \cdot \alpha_i \prod_{j<i} (1 - \alpha_j)$$

Celý proces je **diferencovateľný** ⇒ môžeme optimalizovať parametre!

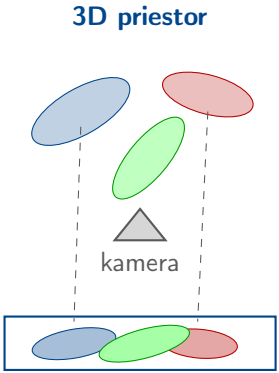

Trénovanie – ako sa Gaussiány učia

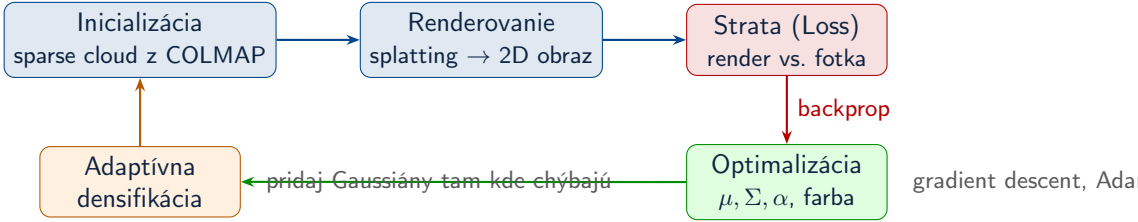

Loss funkcia:

$$\mathcal{L} = (1-\lambda)\mathcal{L}_1 + \lambda\mathcal{L}_{D\text{-}SSIM}$$

porovnáva renderovaný obraz s originálom

Priebeh trénovania:

- 30 000 iterácií (default)
- checkpoint po 7 000 a 30 000
- výsledok: `point_cloud.ply`

Výsledky a možnosti zobrazenia

Čo dostaneme?

- súbor `point_cloud.ply` – milióny 3D Gaussiánov
- renderovanie z **ľubovoľného uhlu**
- **real-time** interaktívny viewer

Typický výsledok – truck dataset

Iterácie	PSNR
7 000	$\approx$ 24.7 dB
30 000	$\approx$ 27.5 dB

SIBR Gaussian Viewer

- interaktívna 3D navigácia
- ovládanie: WASD + myš
- pohľad z pozícií trénovacích kamier

Metrika kvality: PSNR $\approx$ 27–30 dB = dobrý výsledok (30+ dB = výborný)

Kde sa používa?

- VR/AR – interaktívne scény
- robotika – mapovanie prostredia
- kultúrne dedičstvo – digitalizácia
- filmová produkcia
- **priemyselná inšpekcia**

Cvičenie – čo budete robiť

Prostredie – Docker

Všetko je v Docker image:

- COLMAP 3.9.1 (GUI + CUDA)
- 3D Gaussian Splatting
- SIBR Viewer

Spustenie: `./run.sh`

Kamera Ximea

- priemyselná kamera s vysokým rozlíšením
- nasnímajte scénu z **min. 50 uhlov**
- každý bod viditeľný **aspoň 3**×
- uložte do `data/moja_scena/input/`

Postup

1. `./run.sh` – spusti Docker
2. `colmap gui` – rekonštrukcia
   - Feature extraction (SIMPLE_PINHOLE)
   - Feature matching (Exhaustive)
   - Reconstruction
   - Export model → `distorted/sparse/0/`
3. `python3 convert.py -s data/scena`
4. `python3 train.py -s data/scena`
5. `SIBR_gaussianViewer_app -m output/<uuid>`

Podrobný postup: NAVOD.md

Tipy pre kvalitné snímanie scény

✔ Správne

- **50–200 fotografií** scény
- veľké **prekrytie** – každý bod z $\geq$3 uhlov
- pomalý pohyb okolo objektu
- rôzne výšky kamery
- **statická scéna** – nič sa nesmie hýbať
- dobré rovnomerné osvetlenie

✘ Problémy

- **lesklé / zrkadlové povrchy** (odlesk mení farbu podľa uhlu)
- **príliš málo fotografií** (COLMAP nenájde dostatok zhôd)
- **pohyb v scéne** (auto, ľudia, vietor)
- **homogénne plochy** (biela stena – žiadne príznaky)

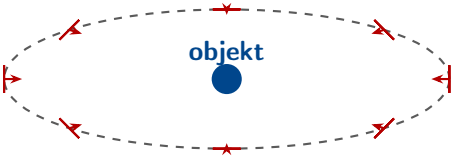

ideálna trajektória
= kruh okolo objektu

Zhrnutie

Čo sme sa naučili

- **COLMAP** (SfM): z 2D fotografií vypočíta polohy kamier a sparse 3D mrak bodov
  – využíva príznaky + RANSAC (prednáška 7)
- **3D Gaussian Splatting**: scéna = milióny 3D Gaussiánov s parametrami $(\mu, \Sigma, \alpha, \text{farba})$
- **Splatting**: projekcia Gaussiánov do 2D + alpha blending
- **Trénovanie**: optimalizácia cez diferencovateľné renderovanie

Na cvičení

1. Nasnímaj scénu kamerou Ximea
2. COLMAP GUI (rekonštrukcia)
3. `convert.py` (undistortion)
4. `train.py` (30–60 min)
5. SIBR Viewer (výsledok!)

Zdroje

- Kerbl et al. SIGGRAPH 2023
- `https://learnopencv.com/3d-gaussian-splatting/`
- `NAVOD.md` v repozitári